Avance de investigacion - Front-End Convolucional 1D en GPU vs. Extracción hand-crafted Log-Mel en BC-ResNet-1

1st Eduardo Mendoza Tapia
Departamento de Electrónica
Universidad Técnica Federico Santa María
Santiago, Chile
eduardo.tapiam@usm.cl

***Abstract*—Este trabajo evalúa experimentalmente la sustitución del extractor manual de espectrogramas Log-Mel en CPU por un front-end convolucional 1D en GPU sobre la arquitectura ultra-compacta BC-ResNet-1 en *Google Speech Commands v2*.la reducción de tiempo por época fue del 15,92%, situándose bajo el 20% proyectado debido a la latencia de I/O en disco (Ley de Amdahl). En clasificación, la exactitud cayó de 96,42% a 89,26%. El análisis FFT confirmó que los filtros 1D aprenden autónomamente la zona formántica vocal (300–3.400 Hz).**

El código utilizado para esta tarea puede encontrarse en el siguiente repositorio de GitHub. El notebook en linea en que se ejecutó puede encontrarse aquí

I. Propuesta de investigación

La arquitectura BC-ResNet-1 [1] demostró un desempeño sobresaliente en el benchmark Google Speech Commands v2 [2], pero depende de un preprocesamiento de los archivos de audio hecha a mano (*hand-crafted*). En este flujo tradicional, la CPU debe calcular la Transformada de Fourier de Tiempo Corto (STFT) y proyectar la energía sobre un banco fijo de 40 filtros triangulares Mel antes de transferir los espectrogramas bidimensionales hacia el acelerador gráfico. Esta separación secuencial introduce un costo computacional y de sincronización en hardware que suele superar la carga de inferencia de la propia red neuronal, restringiendo además la capacidad de adaptación ante variaciones acústicas no modeladas por la escala Mel. Con el fin de abordar esta limitación de representatividad y eficiencia, esta investigación explora la sustitución del extractor manual en CPU por un front-end convolucional 1D que aprende directamente sobre la forma de onda continua en GPU, unificando la extracción de rasgos y la clasificación supervisada en un único grafo de ejecución de extremo a extremo (End-to-End).

A. Research Question

Para investigar la viabilidad de prescindir de la extracción acústica prefijada sin sacrificar el compromiso paramétrico ultra-compacto del modelo, se plantea la siguiente interrogante:

¿En qué medida la sustitución de la extracción artesanal de espectrogramas Log-Mel en CPU por un front-end convolucional 1D sobre audio crudo altera la capacidad de discriminación fonética, la robustez paramétrica y el tiempo de entrenamiento de BC-ResNet-1 sobre Google Speech Commands v2?

B. Hipótesis

La sustitución del extractor manual de espectrogramas Log-Mel en CPU por un front-end convolucional 1D aprendible directamente sobre audio crudo de 16 kHz reducirá el tiempo de reloj por época de entrenamiento en al menos un 20% sobre GPU Tesla T4, alcanzando una exactitud Top-1 en Google Speech Commands v2 que difiere en menos de 1,5 puntos porcentuales respecto al baseline del 96,00%, debido a que el descenso de gradiente estocástico sintoniza los núcleos temporales en bancos de filtros pasabanda que preservan el contraste formántico necesario para alimentar los bloques de broadcasting residual sin depender de transformaciones de Fourier prefijadas.

Esta hipótesis se fundamenta en la dinámica del descenso de gradiente sobre señales acústicas en el dominio del tiempo. Al parametrizar la primera capa con 40 núcleos temporales de 480 muestras (30 ms) y un salto de 160 muestras (10 ms), el algoritmo optimiza directamente coeficientes de respuesta finita al impulso (FIR). Teóricamente, el gradiente forzará a estos filtros a sintetizar bancos pasabanda que concentren su energía en las frecuencias formánticas vocálicas y consonánticas críticas (300 a 3.400 Hz), adaptándose a las regularidades fonéticas del corpus. A nivel de sistemas, la eliminación de las decenas de miles de transformadas discretas en CPU destapa el cuello de botella de transferencia entre memoria host y memoria del acelerador, maximizando el uso de los núcleos CUDA para acelerar el procesamiento de lotes.

La hipótesis se considerará refutada si la reducción en el tiempo medio de época no alcanza la cota mínima del 20%, o bien si la exactitud Top-1 del modelo propuesto en la partición de prueba exhibe una disminución superior a $1,5$ puntos porcentuales respecto a la referencia del $96,00\%$ obtenida por el baseline.

II. Metodología

El marco metodológico se diseñó con el objetivo de asegurar

que cualquier diferencia en las dinámicas de convergencia, la tasa de transferencia computacional y el desempeño predictivo final sea atribuible solo al front-end empleado. Para ello, se estableció una paridad entre la condición de control basada en la arquitectura original y la variante propuesta con front-end de extremo a extremo, congelando la semilla pseudoaleatoria, el dataset de entrenamiento y puesta a prueba, el optimizador, el planificador de tasa de aprendizaje y la cantidad de épocas.

A. Entorno

La experimentación se ejecutó en una instancia de computación acelerada provista por Google Colab con las siguientes caracteristicas:

- SO: Linux x86_64
- GPU: NVIDIA Tesla T4 con 15.360 MiB de memoria VRAM (arquitectura Turing, 2.560 núcleos CUDA y núcleos Tensor de segunda generación)
- CPU: Intel Xeon a $2,20$ GHz
- RAM: $12,7$ GB

El software se estructuró sobre Python 3 utilizando la librerias PyTorch, Torchaudio junto NumPy, Pandas, Scikit-learn, Soundfile, Seaborn y Matplotlib. Para garantizar la persistencia de la información generada ante posibles desconexiones del entorno, se agregó un módulo de respaldo sobre Google Drive.

El dataset utilizado fue Google Speech Commands v2, el cual contiene 105.829 grabaciones monoaurales de un segundo de duración registradas a una frecuencia de muestreo de 16 kHz. Siguiendo el protocolo del modelo BC-Resnet-1 (Kim et al.), el espacio de inferencia se estructuró en doce categorías acústicas discretas y mutuamente excluyentes, compuestas por diez palabras clave objetivo (yes, no, up, down, left, right, on, off, stop, go), una clase representativa de silencio o ruido ambiental de fondo (silence) y una clase distractor fuera de vocabulario (unknown) que agrupa las veinticinco palabras restantes del corpus. Las señales fueron distribuidas conforme a las listas de partición oficiales provistas por el repositorio, asignando 84.843 archivos a la etapa de optimización y ajuste de hiperparámetros, y preservando 11.005 muestras de la partición de prueba oficial para la evaluación de inferencia.

B. Pipeline

El pipeline de datos opera mediante cargadores optimizados de PyTorch que homogeneizan la longitud de cada muestra de audio a 16.000 puntos mediante un operador de relleno (Padding), aplicando un tamaño de lote de $B = 100$ muestras, dos procesos paralelos de lectura asíncrona en memoria host (num_workers=2) y transferencia no bloqueante a memoria fija de paginación (pin_memory=True). A partir de este flujo de entrada común, el pipeline se bifurca en dos ramas experimentales:

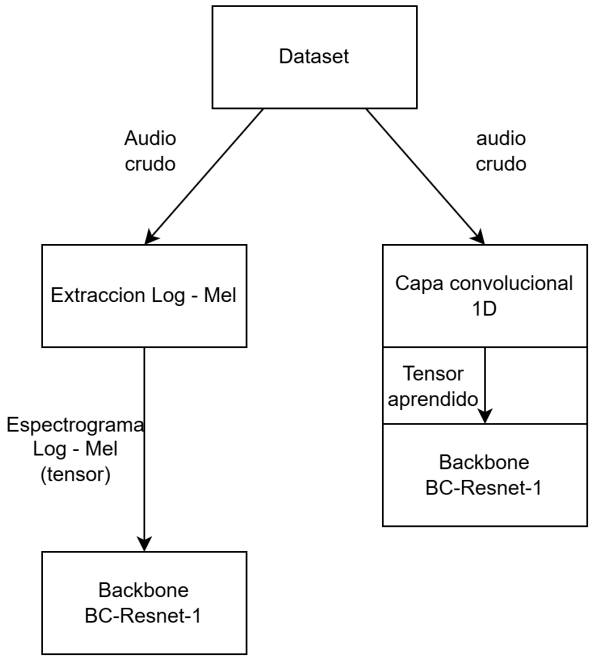


Fig. 1. Flujo del pipeline experimental.

En la condición de control (Baseline), el tensor temporal se procesa a través de la canalización de preprocesamiento tradicional, que calcula la Transformada de Fourier de Tiempo Corto (STFT) empleando una ventana fija de Hanning de 30 ms ($K = 480$ muestras) con un salto temporal de 10 ms, proyectando la energía resultante sobre un banco de 40 filtros triangulares espaciados según la escala perceptual Mel en el rango de 0 a 8.000 Hz. Esto produce un tensor espectro-temporal de dimensiones $[B, 1, 40, 101]$. Este tensor alimenta a la red BC-ResNet-1 ($\tau = 1.0$), la cual procesa la entrada mediante una convolución 2D inicial de 5×5, doce bloques residuales transmitidos (BC-ResBlocks) que integran convoluciones temporales en profundidad con normalización subespectral (SSN) y promediado frecuencial (Frequency Average Pooling), cerrando con un clasificador lineal que totaliza 9.510 parámetros entrenables.

En la arquitectura propuesta, denominada BCResNetRaw, el preprocesamiento desacoplado en CPU se suprime por completo y la forma de onda continua $[B, 1, 16.000]$ se traslada directamente a la GPU. El modelo integra internamente una capa convolucional 1D (nn.Conv1d) con 40 filtros aprendibles, un tamaño de núcleo de $K = 480$ muestras (30 ms a 16 kHz), un paso de traslación de $S = 160$ muestras (10 ms) y un relleno simétrico de 240 muestras sin sesgo aditivo (bias=False), actuando como un banco analítico de filtros de respuesta finita al impulso (FIR). Tras la convolución temporal, la energía de la señal se comprime mediante una función no lineal logarítmica diferenciable $\mathbf{E} = \log(\mathbf{X}^2 + 10^{-6})$, emulando el cómputo de decibeles de la energía espectral, y se estabiliza a través de una capa de normalización por lotes unidimensional (nn.BatchNorm1d(40)). Al expandir la dimensión de canal unitario, el tensor sintetizado de forma interna alcanza di-

mensiones idénticas de $[B, 1, 40, 101]$, acoplándose de manera exacta a los doce bloques residuales de Kim et al. sin alterar la topología interna del backbone. Esta integración incrementa la huella del modelo en 19.280 coeficientes (19.200 pesos en los núcleos temporales y 80 parámetros afines de normalización), dando un total de 28.790 parámetros entrenables optimizados de extremo a extremo.

Ambas redes se entrenaron desde cero durante cuarenta épocas bajo idéntico esquema de optimización. Se empleó el algoritmo de Descenso de Gradiente Estocástico (SGD) con momento $\beta = 0.9$ y regularización L_2 mediante decaimiento de peso (weight decay) fijado en 10^{-3}, calculando los gradientes a partir de la pérdida de entropía cruzada multiclase. La tasa de aprendizaje siguió un régimen estructurado en dos fases: un calentamiento lineal (linear warmup) durante las primeras cinco épocas que elevó η desde 0.0 hasta la tasa base máxima de $\eta_0 = 0.1$, seguido de una atenuación progresiva controlada por un planificador cosenoidal (cosine annealing) que redujo suavemente el gradiente hasta la época final conforme a: $\eta_t = \frac{1}{2}\eta_0 \left(1 + \cos\left(\frac{t - t_{\text{warmup}}}{T - t_{\text{warmup}}}\pi\right)\right)$

Al final de cada época, los modelos se sometieron a inferencia determinista sobre las 9.981 muestras de validación sin cálculo de gradientes, registrando el tiempo de reloj acumulado, la tasa de transferencia (throughput en muestras por segundo) y la exactitud de validación, respaldando el mejor punto de control cuando se estableció un nuevo récord. Finalmente, los modelos con mejor desempeño de cada arquitectura (`best_model_mel.pt` y `best_model_raw.pt`) fueron evaluados sobre los 11.005 audios de prueba para obtener la exactitud Top-1, el índice Macro F1 y las matrices de confusión normalizadas. La interpretabilidad física del front-end aprendido se examinó extrayendo los 40 núcleos temporales para proyectar su respuesta espectral en magnitud $|H(f)|$ mediante la Transformada Rápida de Fourier (FFT) con una resolución de 2.048 puntos en el ancho de banda de Nyquist de 0 a 8.000 Hz, contrastándola contra los triángulos teóricos del banco Mel convencional.

III. Resultados preliminares

La evaluación de la arquitectura propuesta BCResNetRaw frente a la condición de control BC-ResNet-1 sobre las 11.005 muestras de prueba de Google Speech Commands v2 arrojó un conjunto de hallazgos cuantitativos que permiten contrastar la hipótesis formulada. A continuación se exponen los resultados:

Respecto a la eficiencia computacional, la eliminación de la Transformada de Fourier de Tiempo Corto (STFT) en CPU y la introducción directa de la onda temporal en GPU redujo el tiempo total de entrenamiento acumulado a lo largo de las 40 épocas desde $102,97$ minutos en el baseline hasta $86,57$ minutos en la propuesta, representando un ahorro de $16,4$ minutos. Esta ganancia equivale a una reducción en la duración media por época del $15,92\%$ ($129,86$ s por época frente a $154,45$ s en el baseline). Sin embargo, como muestra la Figura 2, la optimización simultánea del banco convolucional y los bloques residuales indujo una función de pérdida más densa y de convergencia más lenta: mientras el baseline descendió por debajo de $0,50$ en la época 5 y concluyó con una pérdida de entrenamiento de $0,1720$, la propuesta requirió más de 30 épocas para llegar a dicho umbral, hasta llegar al final con $0,2898$. Asimismo, la curva de validación de la Figura 3 exhibió fuertes oscilaciones tempranas en el modelo propuesto, cayendo a un mínimo de $38,00\%$ en la época 12 antes de estabilizarse gradualmente hasta registrar su cota máxima de validación en $89,76\%$ en la época 40, contrastando con el ascenso relativamente más monótono del baseline que alcanzó $96,22\%$ en la época 39.

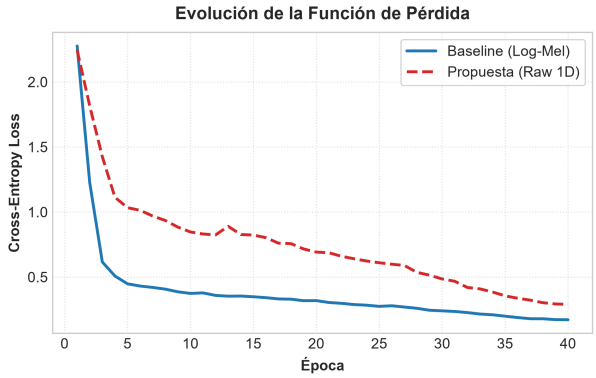


Fig. 2. Evolución de la función de pérdida.

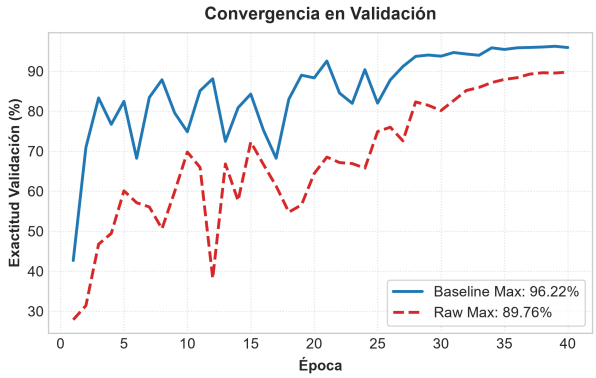


Fig. 3. Convergencia de exactitud sobre el conjunto de validación.

En lo relativo a la capacidad de inferencia sobre la partición de prueba, el modelo BCResNetRaw alcanzó un $89,26\%$ de exactitud y un Macro F1 de $0,8918$, situándose $7,16$ puntos porcentuales por debajo del baseline de control ($96,42\%$ y $0,9640$, respectivamente). Esta brecha de rendimiento global estuvo acompañada por una degradación fonética selectiva sobre los comandos acústicamente vulnerables [2]. El comando go registró una caída de $10,04$ pp en su puntaje F1 (descendiendo de $0,9544$ a $0,8540$), no retrocedió $8,19$ pp ($0,9729$ a $0,8910$), off perdió $8,15$ pp ($0,9514$ a $0,8699$) y up decreció $6,92$ pp ($0,9586$ a $0,8894$). Por el contrario, los comandos dotados de transitorios consonánticos con amplio soporte espectral mostraron una resiliencia superior: stop retuvo un F1 de $0,9642$ (perdiendo solo $2,36$ pp frente

TABLE I
COMPARATIVA DE RESULTADOS PARA AMBOS MODELOS.

Modelo / Enfoque	Parámetros	Tiempo / Época (s)	Throughput (muestras/s)	Tiempo Total (min)	Accurracy (%)	Macro F1
Baseline (Log-Mel CPU)	9.510	154,45	239,63	102,97	**96,42**	**0,9640**
Propuesta (Raw Audio GPU)	28.790	**129,86**	**292,67**	**86,57**	89,26	0,8918
Δ Observado	+19.280 (+202,7%)	-24,59 s (-15,92%)	+53,04 s/s (+22,13%)	-16,40 min (-15,92%)	-7,16 pp	-0,0722

al baseline de $0,9878$), mientras que la clase silence alcanzó un F1 de $0,9951$ con una exhaustividad (recall) del $100,00\%$, superando en $1,32$ pp la marca del baseline $(0,9819)$.

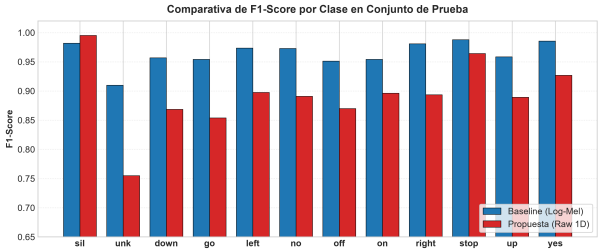


Fig. 4. F1 Score para cada comando en los 2 modelos analizados.

El análisis de las matrices de confusión muestra que la pérdida de exactitud en audio crudo no responde a dispersión estocástica arbitraria, sino a mecanismos de confusión fonética simétrica. Al examinar el par homófono no $\leftrightarrow$ go, el baseline registró únicamente 5 confusiones cruzadas sobre un universo de 807 muestras ($0,62\%$ de confusión mutua: 3 audios de no predichos como go y 2 de go clasificados como no). En contraste, en la arquitectura con front-end 1D este intercambio se sextuplicó hasta alcanzar 32 casos ($3,97\%$ de confusión mutua: 16 de no hacia go y 16 de go hacia no). Una dinámica idéntica se observó en el par labial up $\leftrightarrow$ off, donde la tasa de confusión cruzada escaló desde un $1,57\%$ en el baseline (13 intercambios: 6 de up hacia off y 7 de off hacia up) hasta un $5,20\%$ en la propuesta (43 intercambios: 24 de up hacia off y 19 de off hacia up). En contraste, el par de control ortogonal stop $\leftrightarrow$ yes registró cero confusiones mutuas en ambas arquitecturas ($0,00\%$ de error cruzado), ratificando que el modelo propuesto preserva separabilidad entre categorías fonéticamente disímiles y concentra sus fallos en límites de decisión acústicamente densos.

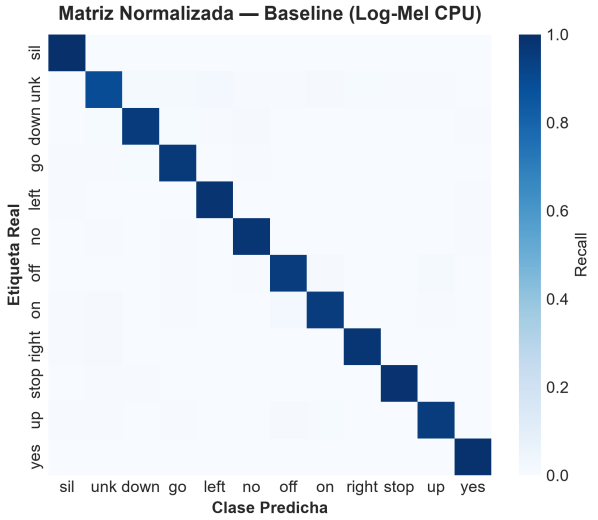


Fig. 5. Matriz de confusión de modelo Baseline.

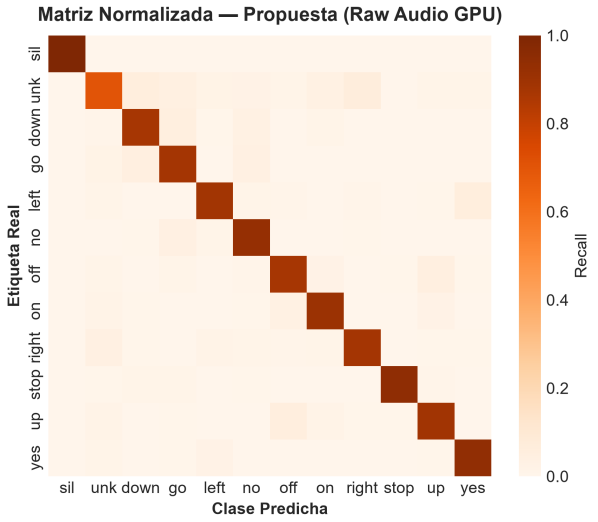


Fig. 6. Matriz de confusión de modelo propuesto.

Finalmente, el examen espectral de los 40 núcleos temporales de la primera capa mediante la Transformada Rápida de Fourier ($N = 2.048$) reveló el comportamiento físico inducido por el descenso de gradiente estocástico sobre la onda de audio. A diferencia de los filtros triangulares Mel, los cuales presentan una respuesta en frecuencia monomodal, simétrica y acotada a lo largo del eje frecuencial lineal-logarítmico, los núcleos aprendidos por la convolución 1D convergieron de

forma no paramétrica hacia bancos pasabanda que concentran su ganancia principal en la zona de formantes vocálicos del habla humana (300 a 3.400 Hz), atenuando fuertemente el contenido armónico por encima de los 7.000 Hz. No obstante, dicha respuesta espectral exhibe una morfología multimodal con lóbulos laterales irregulares (side lobes) y picos armónicos secundarios distribuidos en la banda de 5.000 a 6.500 Hz, lo que evidencia que la optimización libre sin regularización analítica sintetizó filtros con selectividad frecuencial inferior a la escala Mel, explicando físicamente la mayor vulnerabilidad ante fonemas de baja energía.

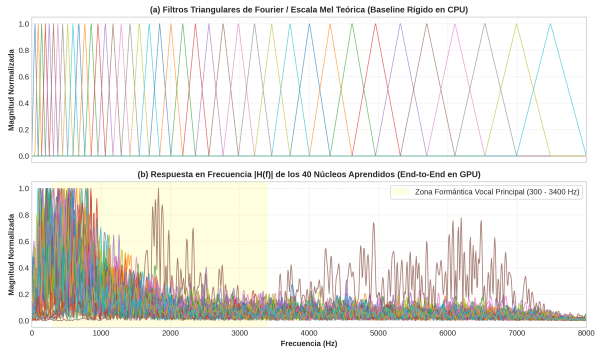


Fig. 7. (a) banco teórico de 40 filtros Mel en CPU y (b) respuesta espectral $|H(f)|$ de los 40 núcleos 1D aprendidos por SGD.

IV. Análisis

La comparación entre el Baseline y la variante propuesta permite evaluar el principio de falsabilidad que rige esta investigación. Los datos obtenidos sobre la partición oficial de prueba refutan los dos postulados en la hipótesis de trabajo: la aceleración media por época se situó en un $15,92\%$ (frente al umbral mínimo previsto del 20%), mientras que la exactitud Top-1 exhibió una brecha desfavorable de $7,16$ puntos porcentuales respecto al baseline ($89,26\%$ frente a $96,42\%$), superando la tolerancia máxima de $1,5$ pp.

El comportamiento de la tasa de procesamiento obtenida se explica a partir de la Ley de Amdahl [4] aplicada a canalizaciones de aprendizaje profundo. La hipótesis asumía que la saturación de la CPU al calcular más de 84.000 transformadas de Fourier por época constituía el factor limitante dominante de la velocidad del sistema. Sin embargo, la persistencia de un techo de aceleración en torno al 16% muestra que el cuello de botella reside en la sobrecarga de metadatos y la latencia de entrada/salida (I/O) del almacenamiento, provocando estancamientos de datos (*data stalls*) documentados en sistemas de aprendizaje profundo [5]. La decodificación de decenas de miles de pequeños archivos .wav de un segundo y la serialización del empaquetamiento en los hilos del cargador de datos imponen un retraso temporal que la GPU Tesla T4 no puede mitigar, permaneciendo inactiva mientras aguarda la transferencia del siguiente lote. Por consiguiente, aunque el front-end en GPU eliminó la carga aritmética de la STFT en la CPU, la ganancia global quedó condicionada por el límite del flujo de datos del sistema anfitrión.

En la dimensión de modelamiento acústico, la degradación de $7,16$ pp en exactitud y de $0,0722$ en Macro F1 responde a dos fenómenos físicos estructurales del front-end convolucional directo. El primer factor radica en la pérdida intrínseca de invariancia de fase temporal. La STFT descarta la fase instantánea al calcular el módulo $|X(t,f)|$, otorgando a la red bidimensional una insensibilidad matemática frente a desplazamientos temporales milimétricos en el inicio de la vocalización. En contraste, una capa convolucional 1D lineal es directamente sensible a la fase de la onda continua; sin una parametrización de filtros en cuadratura (como funciones analíticas apareadas en seno y coseno), la red se ve obligada a gastar capacidad en memorizar réplicas del mismo filtro con diferentes desfases. El segundo factor se observa en la respuesta espectral vía FFT: si bien los 40 núcleos temporales aprendieron autónomamente a amplificar la zona de formantes principales del habla humana (300 a 3.400 Hz), exhiben lóbulos laterales irregulares (side lobes) y resonancias parásitas entre 5.000 y 6.500 Hz que carecen de la selectividad y soporte compacto del banco Mel triangular.

El análisis de las matrices de confusión confirma que el deterioro predictivo no se traduce en clasificaciones aleatorias, sino en un colapso fonético selectivo coincidente con las observaciones de Tang y Lin [6]. En los pares de comandos homófonos (los cuales son no-go, up-off, down-on definidos por P. Warden en [2]) , la tasa de confusión mutua entre no y go se sextuplicó en la arquitectura propuesta ($3,97\%$ frente a $0,62\%$ en el baseline), y la confusión cruzada entre up y off escaló desde $1,57\%$ hasta $5,20\%$, validando la prueba de estrés fonética concebida en el diseño de Warden [2]. Como modela Stevens [7], estos dos pares comparten núcleos vocálicos idénticos (/o/ y //) y se diferencian únicamente por consonantes oclusivas, nasales o fricativas de muy baja energía relativa y corta duración temporal. Al colapsar las frecuencias en el bloque residual mediante Frequency Average Pooling, la baja selectividad de los filtros 1D aprendidos disuelve estos transitorios sutiles. En contraste, el par de control ortogonal stop frente a yes retuvo un error mutuo del $0,00\%$ en ambos modelos. La presencia de fricativas sibilantes intensas (/s/) y silencios oclusivos (/t/, /p/) genera una huella espectral de alto contraste [6], [7] que el modelo en audio crudo aísla con perfecta discriminabilidad.

Limitaciones encontradas

El régimen de entrenamiento presentó un trade-off ineludible. La restricción temporal de las sesiones de Colab obligó a fijar el protocolo experimental en 40 épocas totales con planificador cosenoidal, contrastando con las 200 épocas implementado por Kim et al. en la publicación original. Aunque el baseline demostró una asimilación rápida alcanzando el $96,42\%$ en ese periodo, la curva de pérdida de la propuesta cruda evidencia que el aprendizaje conjunto de representaciones espectrales y capas residuales requería una fase de exploración temporal sustancialmente más prolongada para estabilizar los mínimos del gradiente.

V. Conclusiones preliminares

Este avance evaluó la sustitución del preprocesamiento artesanal Log-Mel en CPU por un front-end convolucional 1D aprendible directamente en GPU sobre la arquitectura BC-ResNet-1. A nivel de sistemas, la propuesta demostró una aceleración al reducir la duración media por época en un 15,92% e incrementar el throughput en un 22,13% sobre GPU Tesla T4. No obstante, las cotas de la hipótesis resultaron refutadas: el ahorro de tiempo no alcanzó el 20% debido al cuello de botella de I/O en disco (Ley de Amdahl [4]), mientras que la exactitud Top-1 cayó de 96,42% a 89,26% ($-7,16$ pp), excediendo con la tolerancia máxima de 1,5 pp.

References

[1] B. Kim, S. Chang, J. Lee, and D. Sung, "Broadcasted Residual Learning for Efficient Keyword Spotting," in *Proc. Interspeech 2021*, 2021, pp. 4531–4535.

[2] P. Warden, "Speech Commands: A Dataset for Limited-Vocabulary Speech Recognition," *arXiv preprint arXiv:1804.03209*, 2018.

[3] Qualcomm AI Research, "BC-ResNet: Broadcasted Residual Learning for Efficient Keyword Spotting," 2021. [En línea]. Disponible en: https://github.com/Qualcomm-AI-research/bcresnet.

[4] G. M. Amdahl, "Validity of the single processor approach to achieving large scale computing capabilities," in *Proc. AFIPS Spring Joint Comput. Conf.*, 1967, pp. 483–485.

[5] J. Mohan, A. Phanishayee, J. Kulkarni, and V. Chidambaram, "Analyzing and mitigating data stalls in DNN training," *Proc. VLDB Endow.*, vol. 14, no. 5, pp. 771–784, 2021.

[6] R. Tang and J. Lin, "Honk: A PyTorch reimplementation of convolutional neural networks for keyword spotting," in *Proc. Interspeech*, 2017, pp. 4531–4535.

[7] K. N. Stevens, *Acoustic Phonetics*, ser. Current Studies in Linguistics. Cambridge, MA, USA: MIT Press, 1998.