Evaluación de Front-End Convolucional 1D en GPU vs. Extracción Log-Mel en BC-ResNet-1

Eduardo Mendoza Tapia · IPD440 · UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA

RESEARCH QUESTION E HIPÓTESIS

PREGUNTA DE INVESTIGACIÓN

"¿En qué medida la sustitución de la extracción artesanal de espectrogramas Log-Mel en CPU por un front-end convolucional 1D sobre audio crudo altera la capacidad de discriminación fonética, la robustez paramétrica y el tiempo de entrenamiento de BC-ResNet-1 sobre Google Speech Commands v2?"

HIPÓTESIS

"La sustitución del extractor manual de espectrogramas Log-Mel en CPU por un front-end convolucional 1D aprendible directamente sobre audio crudo de 16 kHz reducirá el tiempo de reloj por época de entrenamiento en al menos un 20% sobre GPU Tesla T4, alcanzando una exactitud Top-1 en Google Speech Commands v2 que difiere en menos de 1,5 puntos porcentuales respecto al baseline del 96,00%, debido a que el descenso de gradiente estocástico sintoniza los núcleos temporales en bancos de filtros pasabanda que preservan el contraste formántico necesario para alimentar los bloques de broadcasting residual sin depender de transformaciones de Fourier prefijadas."

- Reducción de tiempo por época: **≥ 20% en GPU Tesla T4**
- Cota de exactitud: **Diferencia < 1,5 pp frente a baseline (96,00%)**

DIMENSIONES METODOLÓGICAS

Metodología y Setup Experimental

Configuración controlada de arquitectura, corpus, representación acústica y optimización

1. ARQUITECTURA DEL MODELO

Modelado Acústico y Front-End 1D

- **MODELO BASELINE:** BC-ResNet-1 (9.510 parámetros entrenables).
- **MODELO PROPUESTA:** BCResNetRaw (28.790 parámetros entrenables, +202,7% de sobrecarga paramétrica por filtros FIR).
- **FRONT-END 1D:** nn.Conv1d (40 filtros FIR aprendibles, kernel K=480 equivalente a ventana de 30 ms @ 16 kHz, stride S=160 salto temporal de 10 ms, sin término de sesgo bias=False) + compresión logarítmica de energía instantánea $E=\log(X^2+10^{-6})$ + normalización BatchNorm1d.

2. DATASET Y CORPUS

Google Speech Commands v2

- **DATASET:** Google Speech Commands v2.
- **CORPUS:** 105.829 archivos de audio de 1 segundo de duración a 16 kHz.
- **PARTICIÓN:** 84.843 audios de entrenamiento/optimización, 11.005 audios de test oficial.
- **CLASES (12):** 10 palabras de comando clave ('yes', 'no', 'up', 'down', 'left', 'right', 'on', 'off', 'stop', 'go'), silencio ambiental ('silence') y clase distractor ('unknown').

3. ENTRADA ACÚSTICA

Representación y Flujo de Entrada

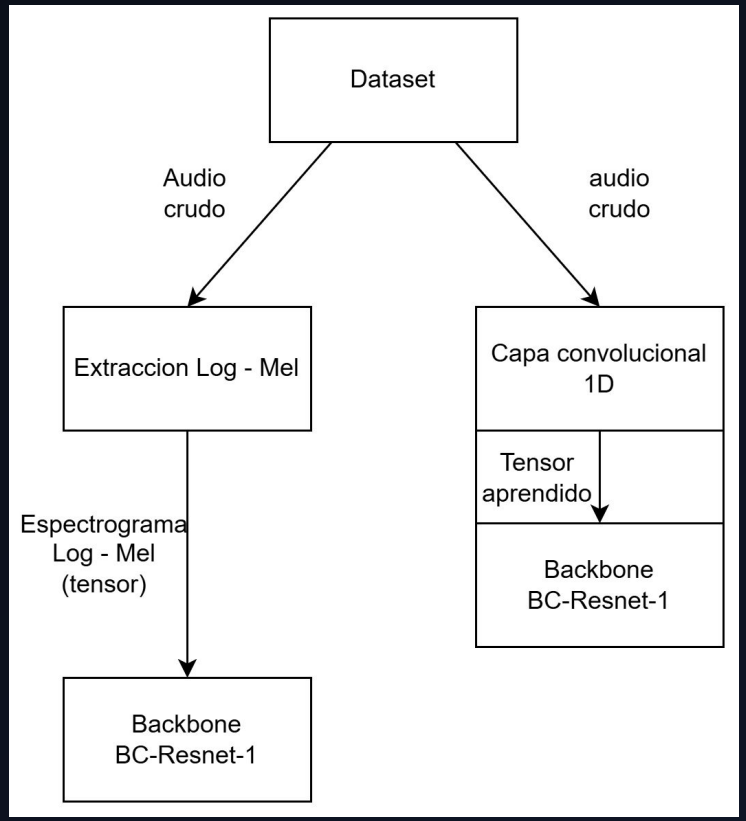
- **CONDICIÓN CONTROL:** Espectrogramas Log-Mel precalculados en CPU con 40 bancos triangulares de frecuencia, ventana Hanning 30 ms, salto 10 ms, tensor resultante [B, 1, 40, 101].
- **CONDICIÓN PROPUESTA:** Forma de onda cruda directa [B, 1, 16.000] trasladada directamente a VRAM en GPU sin transformaciones previas.

4. ENTORNO Y OPTIMIZACIÓN

Infraestructura y Régimen de Entrenamiento

- **HARDWARE:** GPU NVIDIA Tesla T4 (15.360 MiB VRAM), CPU Intel Xeon @ 2,20 GHz, 12,7 GB RAM (Google Colab).
- **RÉGIMEN:** 40 épocas, optimizador SGD (momento 0,9, weight decay 10^{-3}).
- **TASA DE APRENDIZAJE:** Linear Warmup (5 épocas) + Cosine Annealing decay, tamaño de batch B=100.

Pipeline Experimental y Comparativa de Flujo

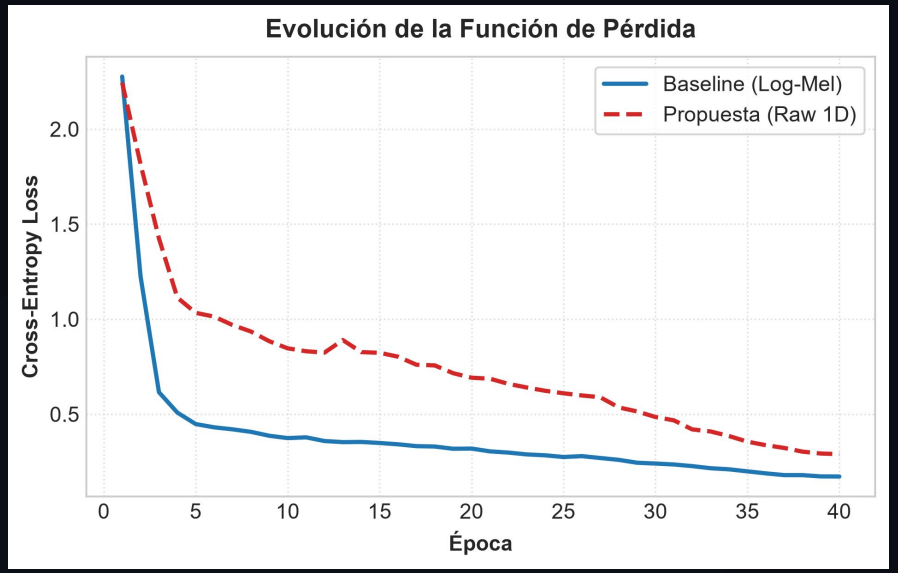


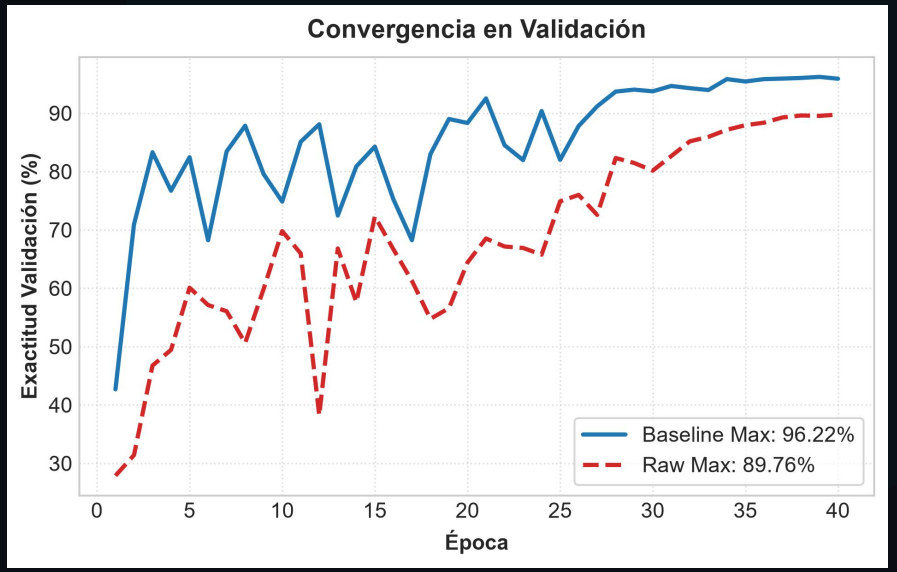
RESULTADOS

TABLE I
COMPARATIVA DE RESULTADOS PARA AMBOS MODELOS.

Modelo / Enfoque	Parámetros	Tiempo / Época (s)	Throughput (muestras/s)	Tiempo Total (min)	Accurracy (%)	Macro F1
Baseline (Log-Mel CPU)	9.510	154,45	239,63	102,97	**96,42**	**0,9640**
Propuesta (Raw Audio GPU)	28.790	**129,86**	**292,67**	**86,57**	89,26	0,8918
Δ Observado	+19.280 (+202,7%)	-24,59 s (-15,92%)	+53,04 s/s (+22,13%)	-16,40 min (-15,92%)	-7,16 pp	-0,0722

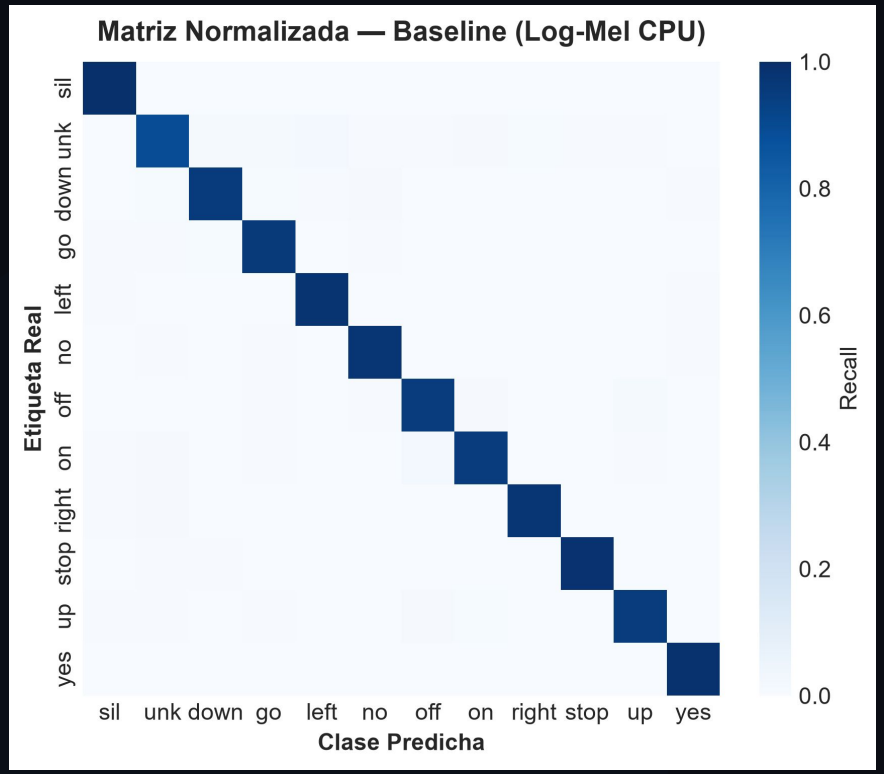
RESULTADOS

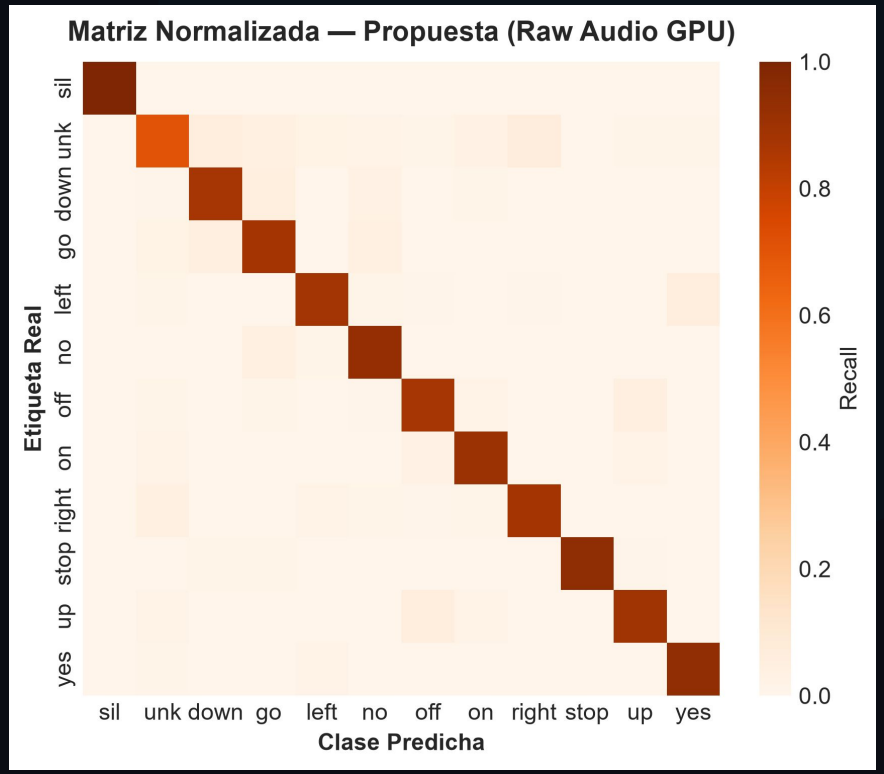




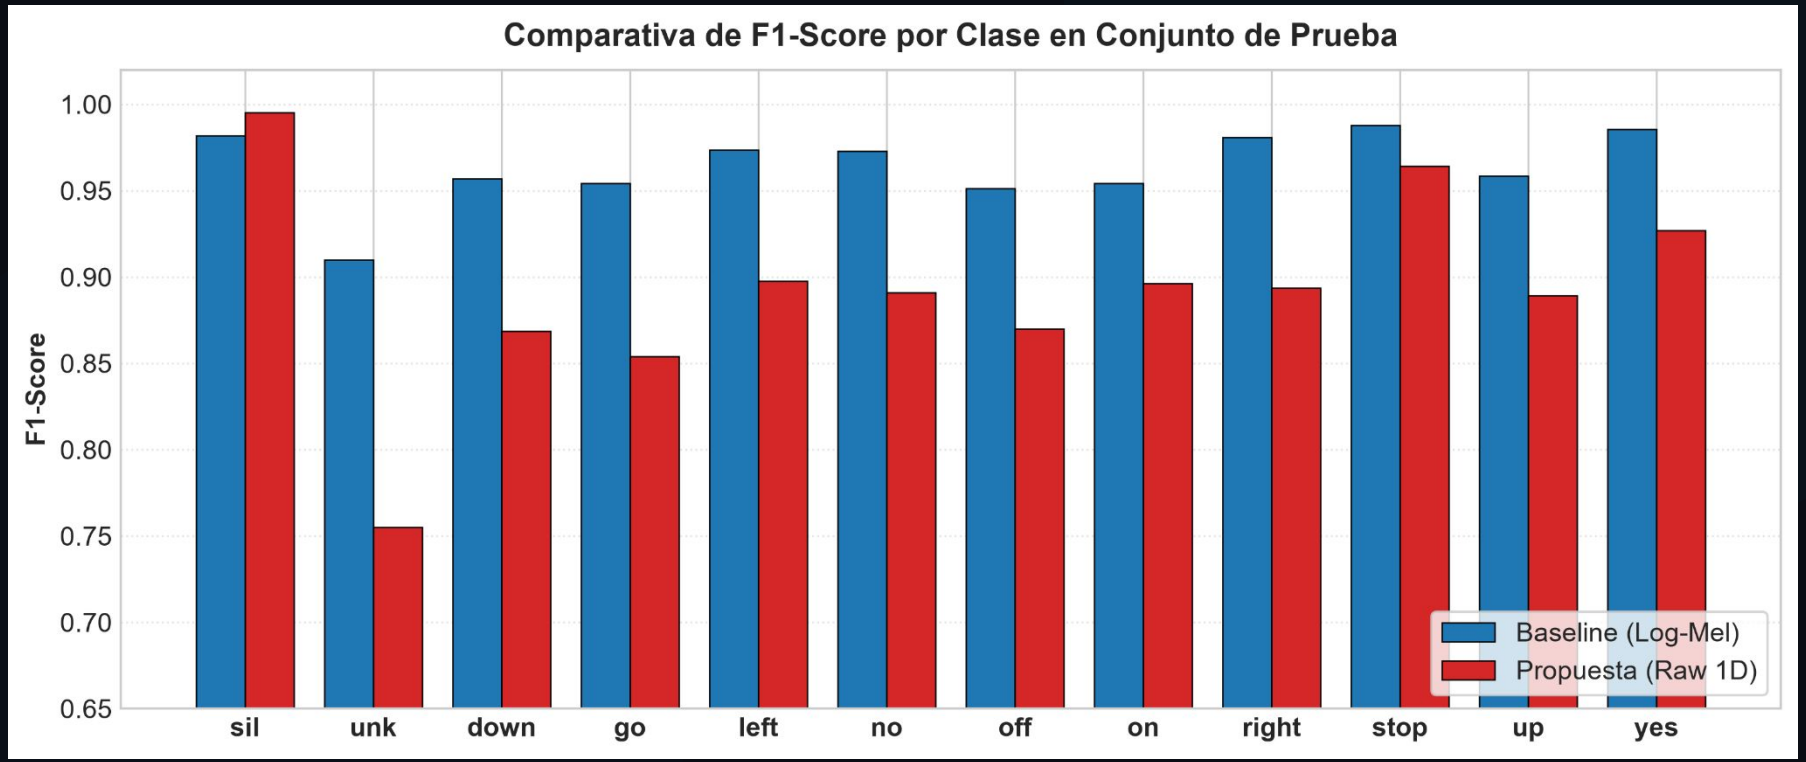
Baseline: 0.1720
Propuesta: 0.2898

RESULTADOS


Matriz Normalizada — Baseline (Log-Mel CPU)
Etiqueta Real
sil
unk
down
go
left
no
off
on
right
stop
up
yes
Clase Predicha
Recall
1.0
0.8
0.6
0.4
0.2
0.0


Matriz Normalizada — Propuesta (Raw Audio GPU)
Etiqueta Real
sil
unk
down
go
left
no
off
on
right
stop
up
yes
Clase Predicha
Recall
1.0
0.8
0.6
0.4
0.2
0.0

RESULTADOS


Comparativa de F1-Score por Clase en Conjunto de Prueba
F1-Score
1.00
0.95
0.90
0.85
0.80
0.75
0.70
0.65
sil
unk
down
go
left
no
off
on
right
stop
up
yes
Baseline (Log-Mel)
Propuesta (Raw 1D)

DESGLOSE DE SENSIBILIDAD ACÚSTICA

Confusión Fonética

Impacto de la pérdida de resolución tiempo-frecuencia en pares mínimos y clases acústicas

ANÁLISIS FONÉTICO MACRO F1: 0,9640 → 0,8918

Descenso promedio global: **-7,16 pp** (Macro F1 baja de 0,9640 a 0,8918)

COMANDOS MÁS VULNERABLES (MAYOR PÉRDIDA)

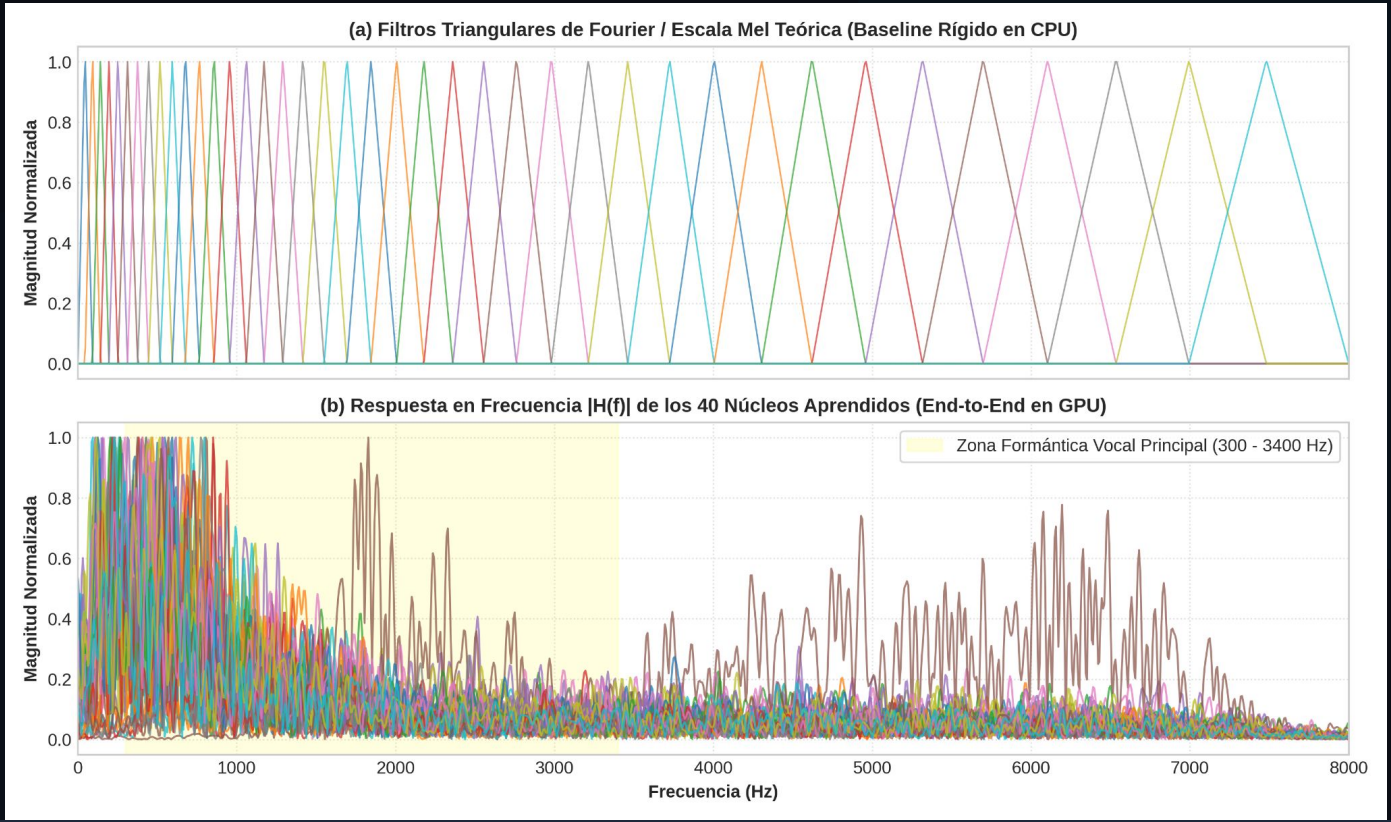
- **Comando 'go':** Cae **-10,04 pp** (F1 de 0,9544 a 0,8540). Más degradada.
- **Comando 'no':** Cae **-8,19 pp** (F1 de 0,9729 a 0,8910).
- **Comando 'off':** Cae **-8,15 pp** (F1 de 0,9514 a 0,8699).
- **Comando 'up':** Cae **-6,92 pp** (F1 de 0,9586 a 0,8894).

COMANDOS RESILIENTES Y SILENCIO

Comando 'stop': Retiene F1 de 0,9642 (apenas cae 2,36 pp vs. 0,9878)
Gracias a sus transitorios espectro-temporales de alta energía (/s/, /t/, /p/).

Clase 'silence': F1 de 0,9951 y 100,00% de recall (+1,32 pp vs. 0,9819)
Excelente desempeño atribuible a la ausencia total de dinámica espectral compleja.

RESULTADOS


(a) Filtros Triangulares de Fourier / Escala Mel Teórica (Baseline Rígido en CPU)
Magnitud Normalizada
1.0
0.8
0.6
0.4
0.2
0.0
(b) Respuesta en Frecuencia |H(f)| de los 40 Núcleos Aprendidos (End-to-End en GPU)
Zona Formántica Vocal Principal (300 - 3400 Hz)
Magnitud Normalizada
0
1000
2000
3000
4000
5000
6000
7000
8000
Frecuencia (Hz)

RESULTADOS

ANÁLISIS

Se refutan formalmente ambos postulados de la hipótesis: el ahorro de tiempo no alcanzó la cota del 20% y la degradación en exactitud superó con creces la tolerancia máxima proyectada de 1,5 pp.

CAÍDA DE EXACTITUD TOP-1

-7,16 pp

Tolerancia máx hipótesis: -1,5 pp **(Exceso de degradación de 5,66 pp)**

ACELERACIÓN POR ÉPOCA

+15,92%

Objetivo de hipótesis: +20,00% **(Déficit de aceleración de 4,08 pp)**